Detección de fraude con aprendizaje supervisado

Minimizar fraudes no detectados sin ignorar las falsas alarmas

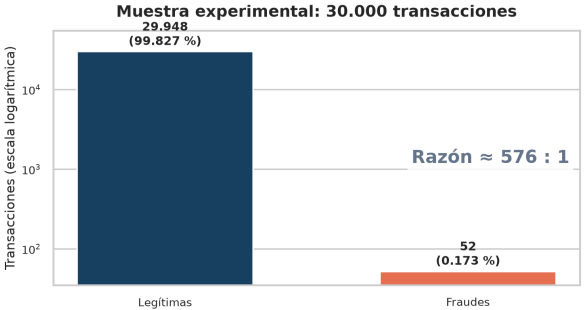
Máximo Mora Diego Álvarez

INFO1185 — Inteligencia Artificial

Octubre de 2026

Objetivo: detectar transacciones fraudulentas priorizando la **minimización de falsos negativos (FNR)**.

1. Datos: el fraude es excepcional

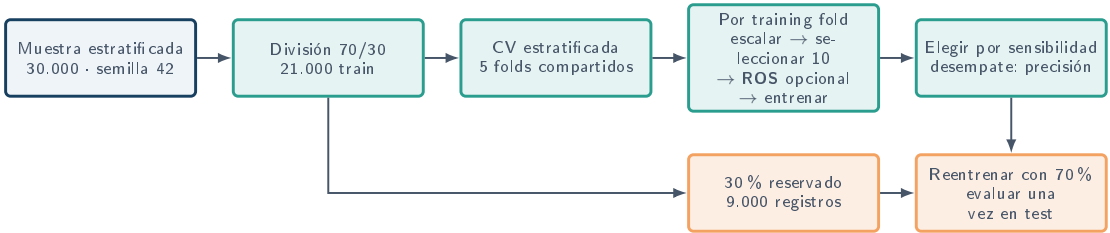


Credit Card Fraud Detection

- Fuente: 284.807 registros; experimento: **30.000**.
- 30 predictores: `Time`, `Amount`, `V1`–`V28`.
- Objetivo: `Class`; fraude = clase positiva.
- 29.948 legítimas y 52 fraudes (0,173 %).

Sin valores faltantes. Los 1.081 duplicados del dataset fuente se conservaron, pero se agruparon al dividir para evitar copias cruzadas.

2. Metodología sin fuga de información



Preprocesamiento

StandardScaler para k-NN/SVM; árboles sin escalado. SelectKBest por información mutua se ajusta dentro de cada fold.

Regla de aislamiento

Validación y test nunca se balancean ni participan en selección de variables, hiperparámetros o umbrales.

3. Cuatro clasificadores, cuatro sesgos inductivos

k-Nearest Neighbors

Vota entre vecinos según distancia. Es sensible a la escala y al valor de k; se evaluaron distancias euclídea y Manhattan.

Support Vector Machine

Busca una frontera con margen amplio. Requiere escalado; se compararon kernels lineal y RBF y distintos valores de C.

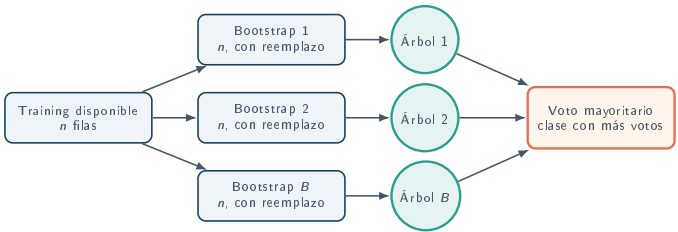
Árbol de Decisión

Divide el espacio con reglas interpretables. Puede sobreajustar; se controlaron profundidad y tamaños mínimos de nodos.

Random Forest propio

Combina árboles diversos mediante bootstrap, aleatoriedad de atributos y voto mayoritario para reducir varianza.

4. Random Forest propio: bootstrap + bagging



Registros repetidos son esperables: cada sorteo se hace **con reemplazo**. Cada árbol aprende una vista distinta.

Implementación real

- `DecisionTreeClassifier` como base.
- `max_features` aleatorio en cada división.
- Semillas únicas derivadas de la semilla 42.
- `n_estimators`, `max_depth`, `max_features` configurables.
- Búsqueda usa 5 u 11 árboles: siempre impar.

No se usa `RandomForestClassifier` ni `BaggingClassifier`.

5. Desbalance: ocho condiciones comparables

Modelo	Sin compensación	Con **ROS**
k-NN	✓	✓
SVM	✓	✓
Árbol	✓	✓
Random Forest propio	✓	✓

Entrenamiento completo: **20.964 : 36**
después de **ROS**: **20.964 : 20.964**

RandomOverSampler

Duplica fraudes elegidos al azar hasta igualar la clase mayoritaria. No inventa puntos sintéticos y conserva todos los ejemplos originales.

Dónde se aplica

Solo al **training fold**, después de escalado/selección. En el Random Forest, cada bootstrap parte de ese training disponible.

Efecto esperado: más fraudes detectados, pero potencialmente más falsos positivos. El resultado debe comprobarse por modelo.

6. Búsqueda y selección de hiperparámetros

Modelo	Espacio acotado: cuatro candidatos
k-NN	$k \in \{3, 5, 7, 11\}$; peso uniforme/distancia; euclídea/Manhattan
SVM	kernel lineal/RBF; $C \in \{0{,}5, 2\}$; γ scale/0,1
Árbol	profundidad libre/12; split 2/20; hoja 1/5; gini/entropía
RF propio	5/11 árboles; profundidad libre/12; $\sqrt{p}/\log_2 p$

Criterio común

Cinco folds compartidos. Maximizar **sensibilidad media**; ante empate, maximizar **precisión media**.

Configuración global seleccionada

SVM lineal + **ROS**

$C = 0{,}5$

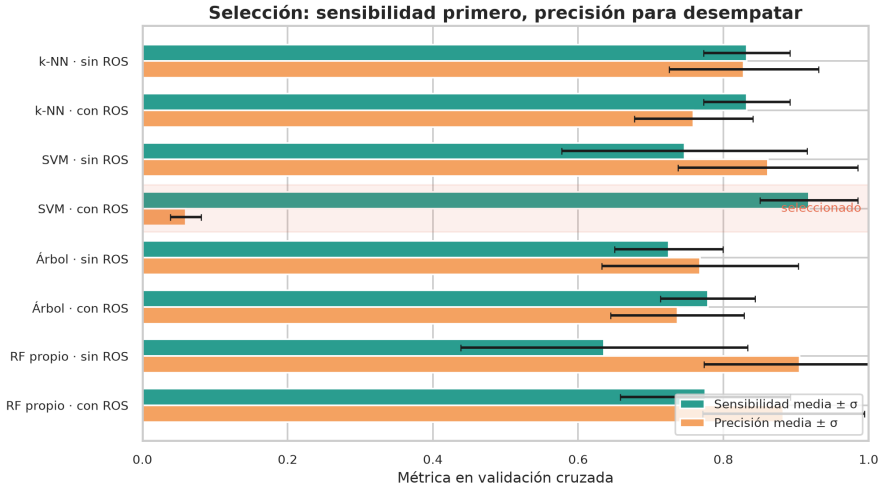
Sensibilidad CV

0,9179 ± 0,0674

FNR CV: 0,0821 ± 0,0674

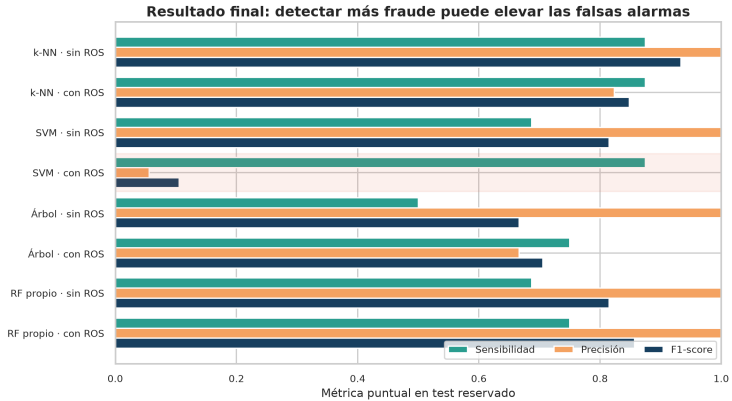
Variables del ajuste final: V3, V4, V7, V10, V11, V12, V14, V16, V17 y V18.

7. Validación cruzada: sensibilidad vs. precisión



La SVM balanceada domina en sensibilidad media, pero anticipa un costo: su precisión media es solo **5,96 %**.

8. Prueba reservada: resultado final de las ocho condiciones



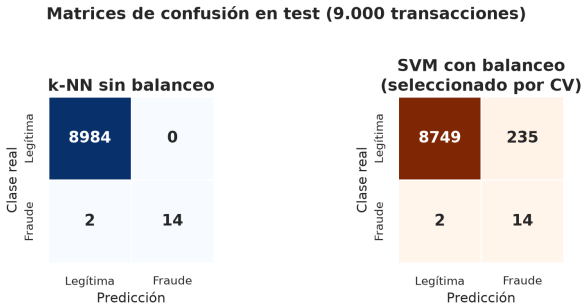
SVM + ROS en test

Sensibilidad	0,8750
Especificidad	0,9738
Precisión	0,0562
F1-score	0,1057
Exactitud	0,9737
FNR	0,1250

TN 8.749 · FP 235 · FN 2 · TP 14

Evaluación única sobre 9.000 casos. Las dispersiones reportadas en respaldo son bootstrap estratificado (200 remuestras) de predicciones fijas, no variación entre reentrenamientos.

9. Análisis crítico: sensibilidad no basta



- **Exactitud engañosa**: siempre legítima logra 99,82 %, pero sensibilidad 0 y FNR 1.
- **Compensar no ayuda igual a todos**: SVM sube en CV, pero en test conserva 14/16 fraudes y agrega 235 falsas alarmas.
- **Árbol vs. bosque**: con balanceo ambos detectan 12/16; el árbol produce 6 FP y el RF propio 0. Bagging mejora estabilidad en este test, sin garantía universal.
- **Siempre fraude**: FNR 0, pero 8.984 FP, precisión 0,18 % y exactitud 0,18 %: operacionalmente inviable.

10. Conclusiones y limitaciones

Qué aprendimos

- CV seleccionó SVM lineal + **ROS** por sensibilidad 0,9179.
- En test detectó 14/16 fraudes, pero solo 5,62 % de sus alertas correspondieron a fraude.
- El RF propio demuestra bootstrap, diversidad de atributos y votación; con **ROS** obtuvo F1 0,8571 y cero FP en este test.
- La exactitud aislada no representa el objetivo del problema.

Límites y próximos pasos

- Solo 52 fraudes en la muestra y 16 en test: alta incertidumbre.
- Variables PCA sin semántica disponible; explicabilidad limitada.
- Sobremuestreo replica casos y puede favorecer sobreajuste.
- Evaluar el dataset completo, calibrar probabilidades y elegir umbral según costos de FN/FP.
- Validar temporalmente ante cambio de patrones de fraude.

Decisión recomendada: priorizar sensibilidad, pero medir siempre el costo operativo.

Respaldo A. Configuraciones seleccionadas por condición

Modelo	Condición	Mejor configuración por CV
k-NN	sin **ROS**	$k = 11$, Manhattan, pesos por distancia
k-NN	con **ROS**	$k = 5$, euclídea, pesos por distancia
SVM	sin **ROS**	lineal, $C = 2$
SVM	con **ROS**	lineal, $C = 0{,}5$
Árbol	sin **ROS**	entropía, profundidad 12, split 20, hoja 5
Árbol	con **ROS**	gini, profundidad libre, split 20, hoja 5
RF propio	sin **ROS**	11 árboles, profundidad libre, `max_features=sqrt`
RF propio	con **ROS**	11 árboles, profundidad libre, `max_features=sqrt`

Respaldo B. Métricas completas de validación cruzada

Modelo	Cond.	Sensibilidad	Especificidad	Precisión	F1	Exactitud	FNR
k-NN	sin	.8321±.0593	.9997±.0002	.8281±.1029	.8254±.0576	.9994±.0002	.1679±.0593
k-NN	con	.8321±.0593	.9995±.0002	.7590±.0816	.7913±.0574	.9992±.0002	.1679±.0593
SVM	sin	.7464±.1692	.9997±.0003	.8614±.1240	.7737±.0910	.9993±.0002	.2536±.1692
SVM	con	.9179±.0674	.9713±.0116	.0596±.0214	.1109±.0368	.9712±.0115	.0821±.0674
Árbol	sin	.7250±.0746	.9996±.0003	.7679±.1354	.7384±.0686	.9991±.0003	.2750±.0746
Árbol	con	.7786±.0655	.9995±.0003	.7367±.0921	.7510±.0451	.9991±.0003	.2214±.0655
RF propio	sin	.6357±.1974	.9998±.0003	.9048±.1313	.7136±.1467	.9992±.0003	.3643±.1974
RF propio	con	.7750±.1172	.9998±.0003	.8829±.1115	.8105±.0507	.9994±.0002	.2250±.1172

Media ± desviación estándar poblacional entre cinco folds del 70 % de entrenamiento.

Respaldo C. Métricas completas de prueba (1/2)

Modelo	Cond.	Sensibilidad	Especificidad	Precisión	F1	Exactitud	FNR
k-NN	sin	.8750±.0852	1.0000±.0000	1.0000±.0000	.9333±.0495	.9998±.0002	.1250±.0852
k-NN	con	.8750±.0852	.9997±.0002	.8235±.0805	.8485±.0655	.9994±.0002	.1250±.0852
SVM	sin	.6875±.1226	1.0000±.0000	1.0000±.0000	.8148±.0874	.9994±.0002	.3125±.1226
SVM	con	.8750±.0852	.9738±.0017	.0562±.0063	.1057±.0117	.9737±.0017	.1250±.0852

Punto estimado ± desviación bootstrap estratificada de 200 remuestras de las predicciones fijas. No son múltiples entrenamientos.

Respaldo D. Métricas completas de prueba (2/2)

Modelo	Cond.	Sensibilidad	Especificidad	Precisión	F1	Exactitud	FNR
Árbol	sin	.5000±.1187	1.0000±.0000	1.0000±.0000	.6667±.1038	.9991±.0002	.5000±.1187
Árbol	con	.7500±.1077	.9993±.0003	.6667±.0952	.7059±.0828	.9989±.0003	.2500±.1077
RF propio	sin	.6875±.1226	1.0000±.0000	1.0000±.0000	.8148±.0874	.9994±.0002	.3125±.1226
RF propio	con	.7500±.1077	1.0000±.0000	1.0000±.0000	.8571±.0719	.9996±.0002	.2500±.1077

Punto estimado ± desviación bootstrap estratificada de 200 remuestras de las predicciones fijas. Matrices completas: `results/figures/issue_8_confusion_matrices.png`.